

Sobre a fonte de dados:

- Onde os dados de pedidos vivem hoje? Banco de dados transacional (OLTP), fila de mensagens, API REST?
- Qual o volume estimado de pedidos por dia/hora? Isso define batch vs. streaming.
- Os dados já têm um schema definido? Quem é o dono desse schema?
- Existe alguma documentação de API ou dicionário de dados disponível?

Sobre os requisitos do negócio:

- Qual a granularidade necessária? O stakeholder quer pedido por SKU, por canal, por região?
- Qual a latência aceitável dos dados? Precisam estar disponíveis em minutos ou D-1 já é suficiente?
- Quem vai consumir esses dados? BI, cientistas de dados, sistema operacional?

Sobre SLA e qualidade:

- Qual o comportamento esperado em caso de falha ou dado faltante?
- Existem requisitos de LGPD ou anonimização para dados de pedidos de usuários?
- Qual o período histórico a ser carregado? Só dados novos ou há necessidade de backfill?

Sobre infraestrutura:

- Qual o ambiente disponível? Cloud (Azure, AWS, GCP)? Já existe um Data Lake?
- O time usa Databricks? Quais permissões estão disponíveis?

Sobre data quality e contratos de dados:

- Existe um SLA de qualidade definido? (ex: aceitar até X% de registros nulos antes de alertar)
- Quem é notificado quando uma regra de qualidade quebra — o time de dados ou o time de negócio?
- O pipeline deve bloquear a carga ou apenas sinalizar quando encontrar dados inválidos?
- Já existe alguma ferramenta de DQ em uso (Great Expectations, dbt tests, Soda)?

Sobre valores anômalos e fraude:

- Existem pedidos de teste ou pedidos internos que devem ser excluídos das análises?
- Um mesmo usuário pode fazer múltiplos pedidos em segundos? (ajuda a calibrar detecção de duplicatas vs. fraude)

- O time de negócio já tem histórico de padrões fraudulentos identificados manualmente?
- A flag de fraude deve bloquear o pedido em tempo real ou é só para análise posterior?

Sobre o ciclo de vida do dado:

- Pedidos podem ser cancelados ou editados após a confirmação? Como isso chega na fonte?
- Como tratar o dado histórico vs. o dado corrigido — sobrescrever ou manter versão?
- Qual o período de retenção dos dados? Existe política de expiração ou arquivamento?

Sobre acesso e governança:

- Quem pode ver dados individuais de pedidos? Existe necessidade de mascaramento de PII?
- As métricas de vendas são sensíveis competitivamente — quem tem acesso à camada Gold?

A arquitetura acima segue o padrão **Medallion (Bronze → Silver → Gold)**, que é o mais adotado em ambientes Databricks/Spark.

Bronze (Raw): os dados chegam exatamente como a fonte entrega — sem transformação. Isso garante rastreabilidade total e permite reprocessamento. Se vier de API, salva como JSON ou Parquet particionado por data de ingestão.

Silver (Cleaned): aqui acontece a limpeza: deduplicação de pedidos, validação de tipos, enforcement de schema, tratamento de nulos. O dado já é confiável, mas ainda não está agregado.

Gold (Curated): modelo dimensional pronto para consumo — fatos de vendas com dimensões de produto, canal, região e tempo. É o que alimenta dashboards de BI e notebooks de análise.

Orquestração com Airflow: cada etapa vira uma DAG com SLA definido, alertas por e-mail/Slack em caso de falha e reprocessamento automático por janela de tempo.

Batch ou Streaming? Depende da resposta do stakeholder sobre latência. Para D-1 (relatórios do dia anterior), batch com Airflow é suficiente. Se precisar de dados em minutos, a camada de ingestão passa a usar Kafka ou Azure Event Hub antes de gravar na Bronze.

